



佛山大学
FOSHAN UNIVERSITY

心脏病智能检测设备与方法

2024年7月29日



佛山大学
FOSHAN UNIVERSITY

目 录

1. 背景与意义
2. 相关工作
3. 研究框架
4. 研究内容
5. 下一步工作



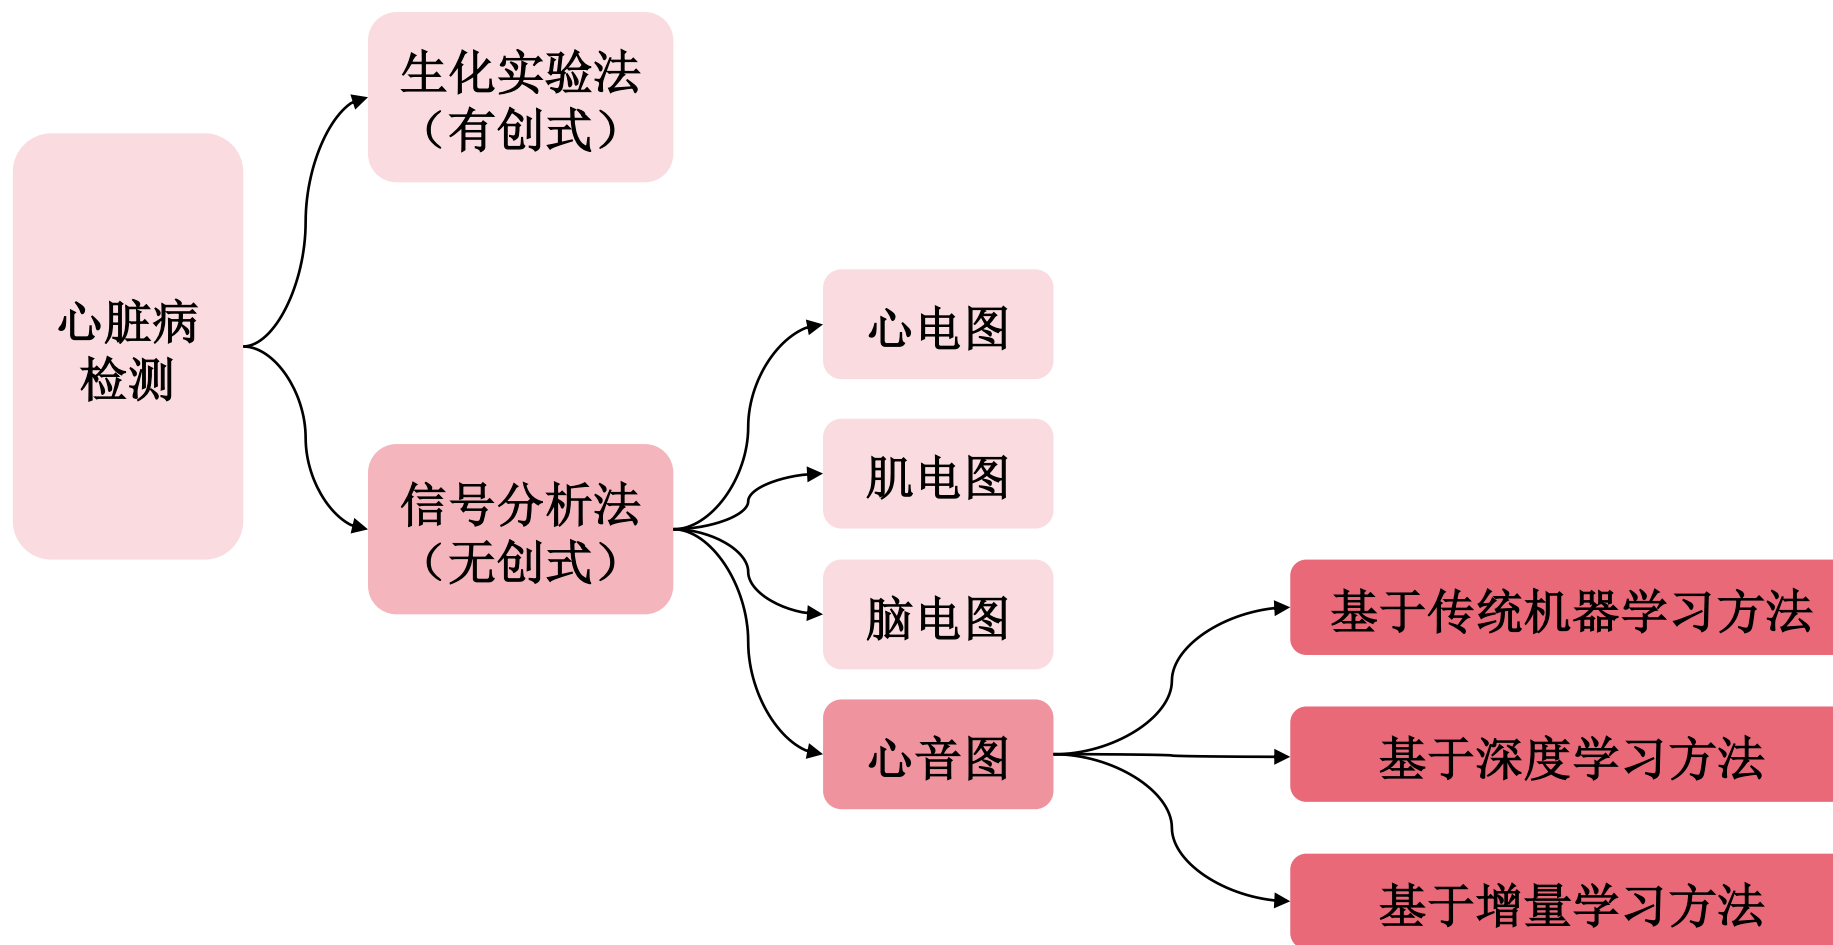
1.背景与意义

2.相关工作

3.研究框架

4.研究内容

5.下一步工作





1.背景与意义

2.相关工作

3.研究框架

4.研究内容

5.下一步工作

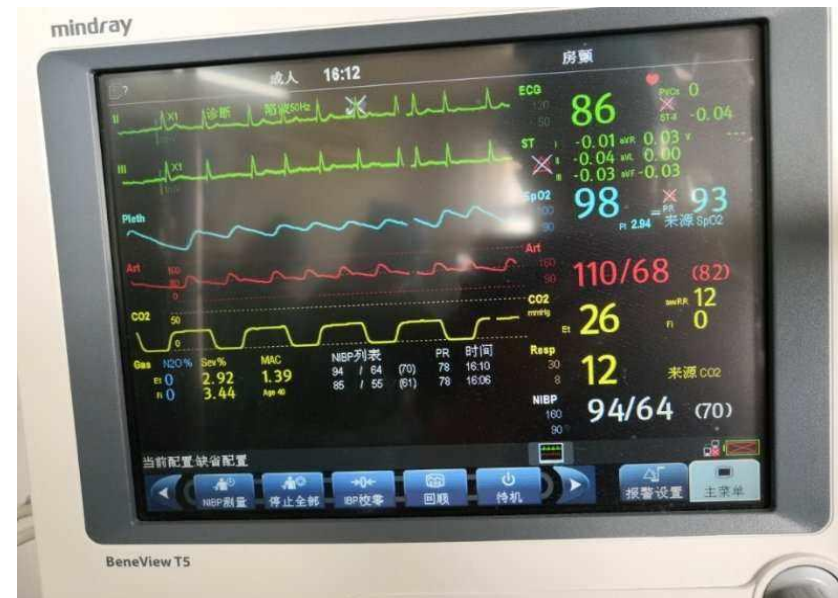
- ❑ 为了准确地进行心脏病的检测，研究者们提出了多种方法，可以将它们大致分为**生化实验法**和**信号分析法**
- ❑ 前者通过测试基因或者分析血液成分的变化来进行检测，这种方法高度依赖于实验室实验，一般**成本较高**
- ❑ 信号分析方法旨在通过分析心电图、肌电图、脑电图和心音等各类生理信号来进行心脏病诊断，相较生化实验法**具有操作简单、时间成本低**等优点



生化实验法（有创心脏功能检查）



信号分析法（无创心脏功能检查）





1.背景与意义


2.相关工作

3.研究框架

4.研究内容

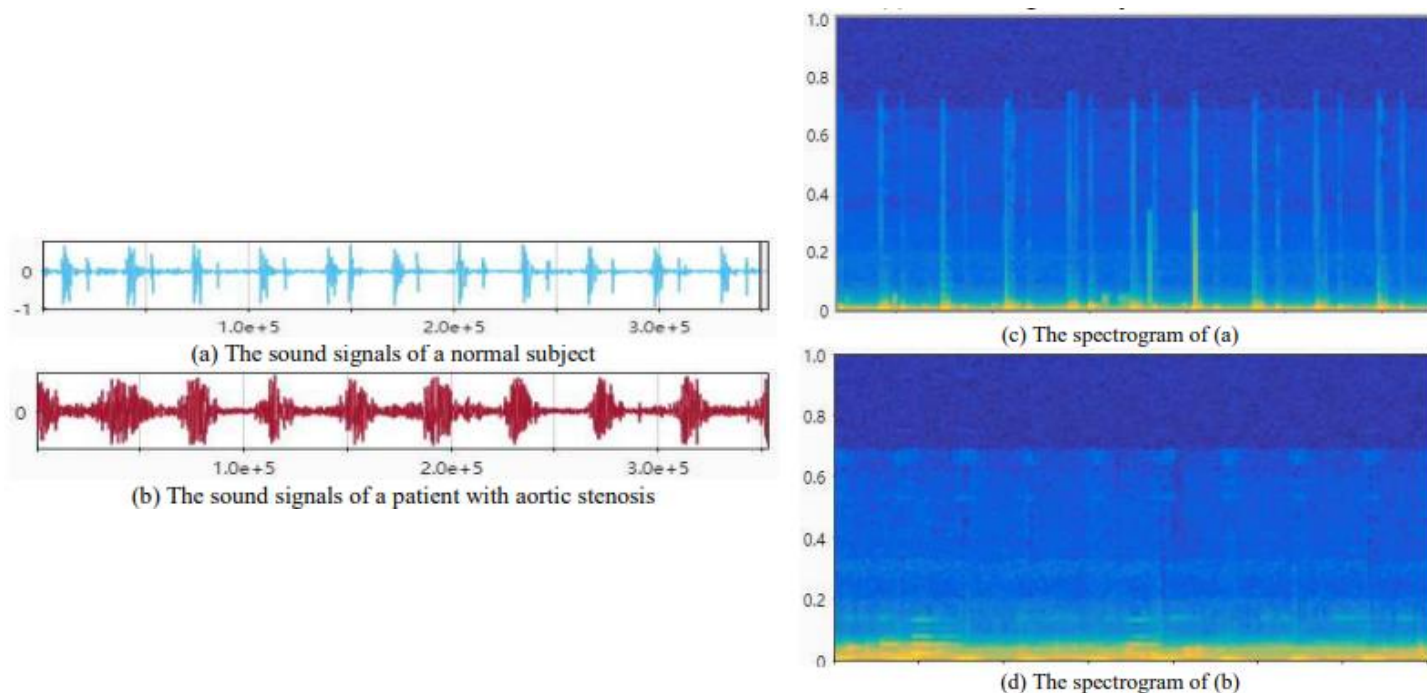
5.下一步工作

- 基于心电图、肌电图、脑电图的识别方法通常较复杂，并且一般需要三个以上的电极，使用起来不方便。与心电图、脑电图、肌电图相比，心音信号包含了心脏各个部分的功能状态的大量生理信号，具有**可采集性**、**普遍性**和**独特性**的生物特征
- 心音信号为获取和了解心脏和心血管系统的状态提供了一种经济便捷的手段，具有**便携性高**、**成本低**、**接受度高**、**信号获取方式简单**等优势。此外，心音检测是一种**无创性检测**方法，对某些心血管病变的敏感性比心电图信号高，往往只需要单导心音信号



S1: 频率10-140Hz; 持续时间50-150ms S2: 频率10-400Hz; 持续时间60-120ms
S3: 频率20-40Hz; 持续时间40-60ms S4: 频率<30Hz; 持续时间S1前50ms

心音信号的特征



正常人和心脏病患者的信号图对比

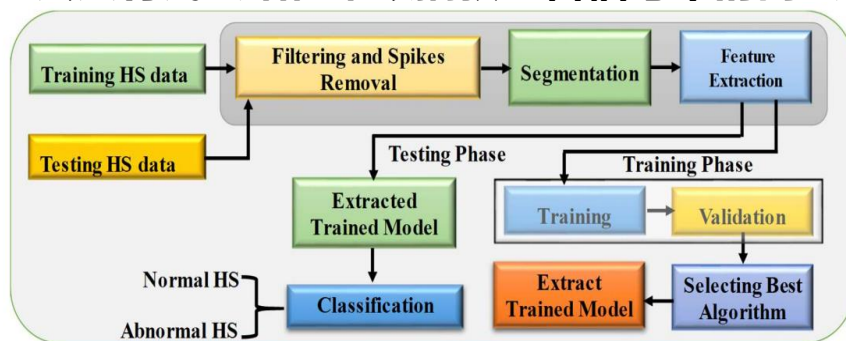


■ 基于心音信号的心脏病检测方法：传统方法

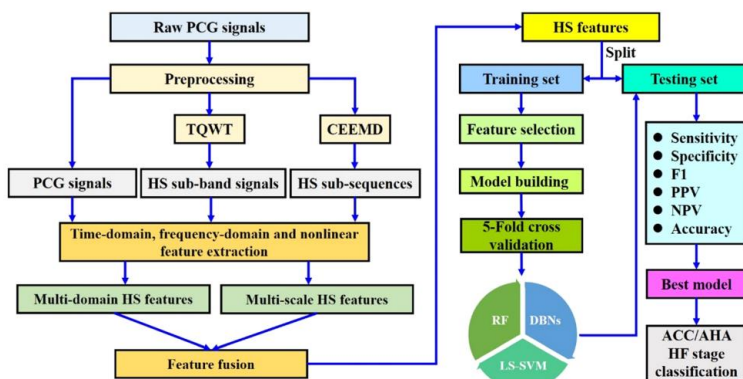
■ 基于心音信号的心脏病检测方法

- 包括训练过程和预测过程
- 训练过程：去噪、流式心音信号分段、特征提取、模型训练

■ 此类方法具有浅层结构难以捕获心音信号中的高层语义关系



Chowdhury等基于机器学习的异常检测算法块



Zheng等基于LS-SVM框架的心音分类

■ tsfresh:时序数据特征自动提取工具

- tsfresh 是一个用于时间序列特征生成的python包。使用 tsfresh可以自动计算出大量的时间序列特征， tsfresh还内置有特征筛选算法可以挑选出和任务有关的特征。提取的特征可用于描述时间序列， 这些特征可以用于下游的时间序列任务， 如股票价格预测、天气预测、景点人流预测、时尚商品销量预测、商品推荐系统等。

□ tfresh的特点：

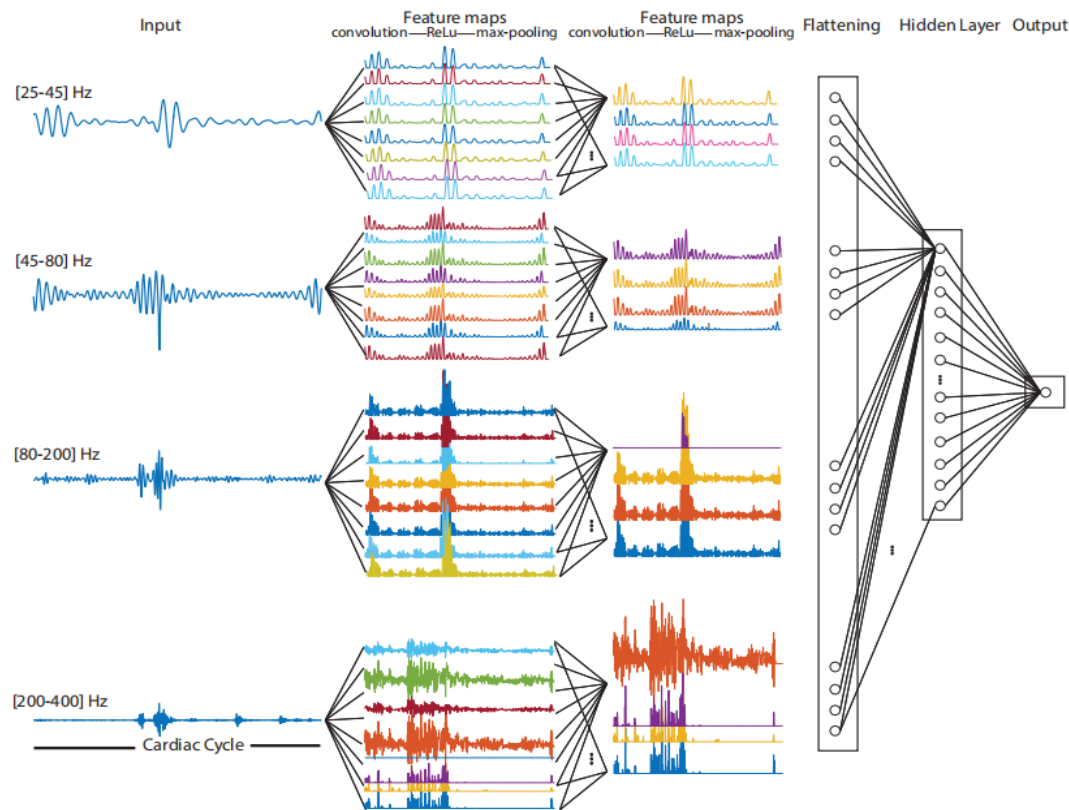
1. 安装方便， 使用简单
2. 内置数百个在各个领域验证有效的特征生成函数可调用
3. 支持设置目标进行特征过滤
4. 支持自定义新的特征函数
5. 支持对滚动时间序列提取特征
6. 支持使用Dask在处理大样本数据
7. 支持进行并行化加速
8. 可以和scikit-learn进行结合使用




■ 基于心音信号的心脏病检测方法：深度学习方法

■ 利用深度学习模型挖掘心音信号中的非线性语义关系

- Potes等提出利用卷积神经网络(CNN)挖掘心音信号中的局部不变性和平移不变性
- Sujadevi等提出利用长短时记忆网络(LSTM)挖掘心音信号中的长期依赖关系



用于正常/异常心音分类的CNN架构



LSTM 存储单元中的单元

- Chowdhury M E H, Khandakar A, Alzoubi K, et al. Real-Time Smart-Digital StethoscopeSystem for Heart Diseases Monitoring[J]. Sensors, 2019, 19(12):2781.
- Zheng Y, Guo X, Wang Y, et al. A multi-scale and multi-domain heart sound feature-based machine learning model for ACC/AHA heart failure stage classification[J]. Physiological Measurement, 2022, 43(6): 065002.
- Potes C, Parvaneh S, Rahman A, et al. Ensemble of feature-based and deep learning-based classifiers for detection of abnormal heart sounds[C]//2016 computing in cardiology conference (CinC). IEEE, 2016: 621-624.
- Sujadevi V G, Soman K P, Vinayakumar R, et al. Deep models for phonocardiography (PCG) classification[C]//2017 international conference on intelligent communication and computational techniques (ICCT). IEEE, 2017: 211-216.



■ 基于心音信号的心脏病检测方法对比

□ 数据集：2016 PhysioNet/CinC Challenge Dataset

	作者	模型	准确率	优点	不足
传统机器学习方法	Chowdhury等	SVM+KNN	86.02%	模型简单，适用广泛	需对原始数据进行特征提取，且需要大量样本数据。泛化能力差
	Zheng等	LS-SVM	82.00%		
深度学习方法	Noman等	CNN	89.22%	不需要选择提取特征，性能较好	需要大量数据，并且对算力要求高
	Xu等	SMGU-RNN (based LSTM)	88.50%		
	Chen等	MS-ResNet-RNN	93.50%		

- Chowdhury M E H, Khandakar A, Alzoubi K, et al. Real-Time Smart-Digital StethoscopeSystem for Heart Diseases Monitoring[J]. Sensors, 2019, 19(12):2781.
- Zheng Y, Guo X, Wang Y, et al. A multi-scale and multi-domain heart sound feature-based machine learning model for ACC/AHA heart failure stage classification[J]. Physiological Measurement, 2022, 43(6): 065002.
- Noman, Fuad, et al. "Short-segment heart sound classification using an ensemble of deep convolutional neural networks." ICASSP 2019-2019 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2019.
- Xu, Chundong, et al. "Heart sound segmentation based on SMGU-RNN." BIBE 2019; The Third International Conference on Biological Information and Biomedical Engineering. VDE, 2019.
- Chen, Qianru, et al. "Heart Sound Classification Based on Mel-Frequency Cepstrum Coefficient Features and Multi-Scale Residual Recurrent Neural Networks." Journal of Nanoelectronics and Optoelectronics 17.8 (2022): 1144-1153.



1.背景与意义

2.相关工作

3.研究框架

4.研究内容

5.下一步工作

研究内容1

基于混合注意时间卷积网络的心脏病检测模型

- 充分挖掘心音信号中的复杂时空信息
- 解决了深层网络中梯度消失或梯度爆炸问题带来的影响，促进模型训练
- 捕获心音信号之间的高阶动态时空依赖性

研究内容3


集成研究内容1和研究内容2的成果，基于边缘计算技术，开发相应的原型系统，提供远程医疗服务

- 当前医疗资源分布不平衡，偏远地区现场就医困难

研究内容2

基于增量学习的心脏病检测模型

- 调整已有的心脏病预测模型来适用“开放世界”
- 已有的工作主要关注“封闭世界”，即如果当前的心脏病预测模型可用于识别“健康A”和“心率失常B”时，当给定来自“冠心病C”的心音信号时，该模型将不可能做出正确预测
- 收集“新类别”的数据后，连同已有类别的数据一起重新训练预测模型，成本高；用“新类别”的数据微调预测模型，容易产生灾难性遗忘





1.背景与意义

2.相关工作

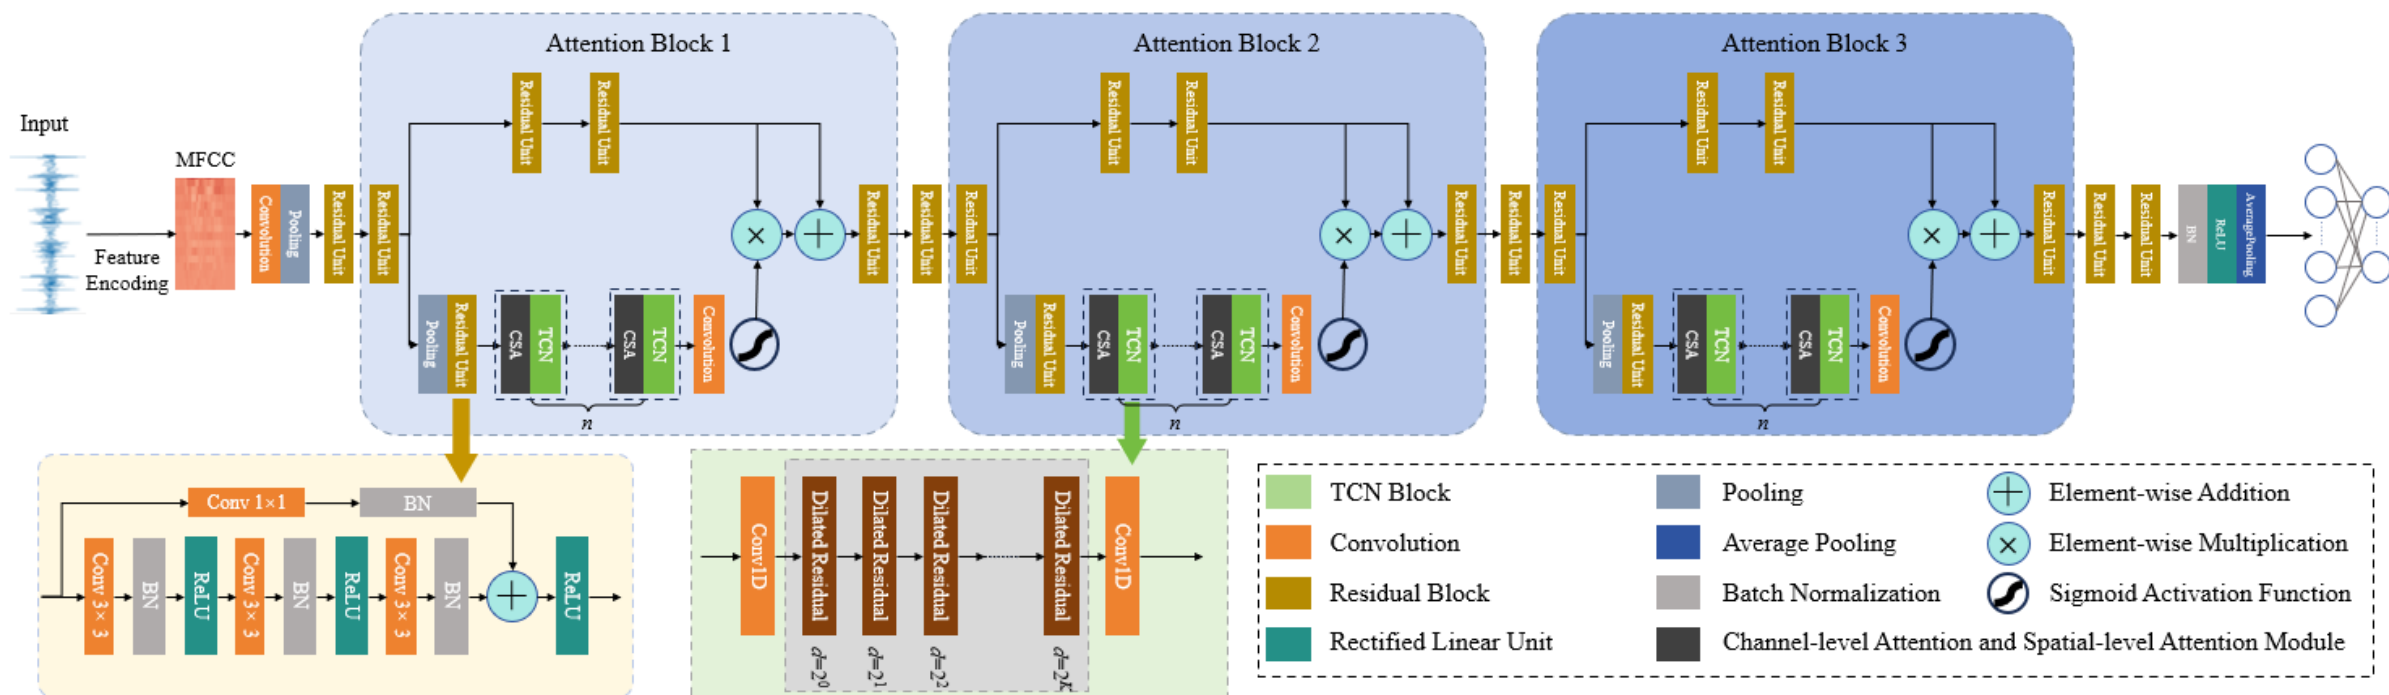
3.研究框架

4.研究内容

5.下一步工作

■ 研究内容1：基于注意力机制的心脏病检测模型

- 解决的问题：针对目前心音识别在时序数据中不同阶段对关键特征的动态聚焦具有**局限性**和心音本身的**复杂性**以及受试者之间和受试者内部的**差异**，未能充分考虑心音信号中的时空信息，深层网络中梯度消失或梯度爆炸问题带来的影响以及处理大规模数据集时训练不高效。
- 方法的基本原理：本研究通过探索从数据驱动模型优化的角度捕获心音信号之间的高阶动态时空依赖性，提出了**残差注意时间卷积网络**，更好地分析心音信号并提高识别准确性。
- 本研究探索了**时间卷积网络**来模拟长程依赖关系**增加感受野**，并将其进一步集成到残差单元中，以促进深度模型训练。此外，RATCNet还构建了通道级和空间级注意机制的混合来**动态调整权重**，以突出具有区分性的时空特征图。此外，多个 RATCNet 可以无缝、轻松地堆叠在一起，形成更深层次的神经网络



基于注意力机制的心脏病检测模型



1.背景与意义

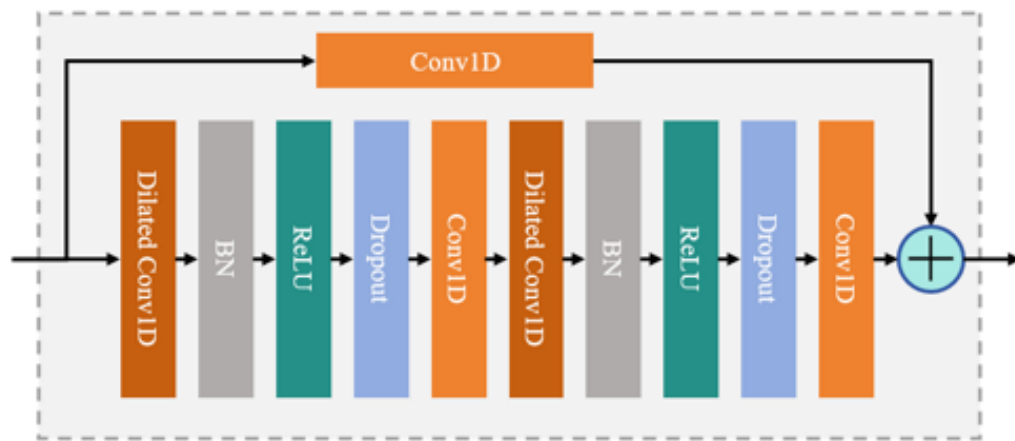
2.相关工作

3.研究框架


4.研究内容

5.下一步工作

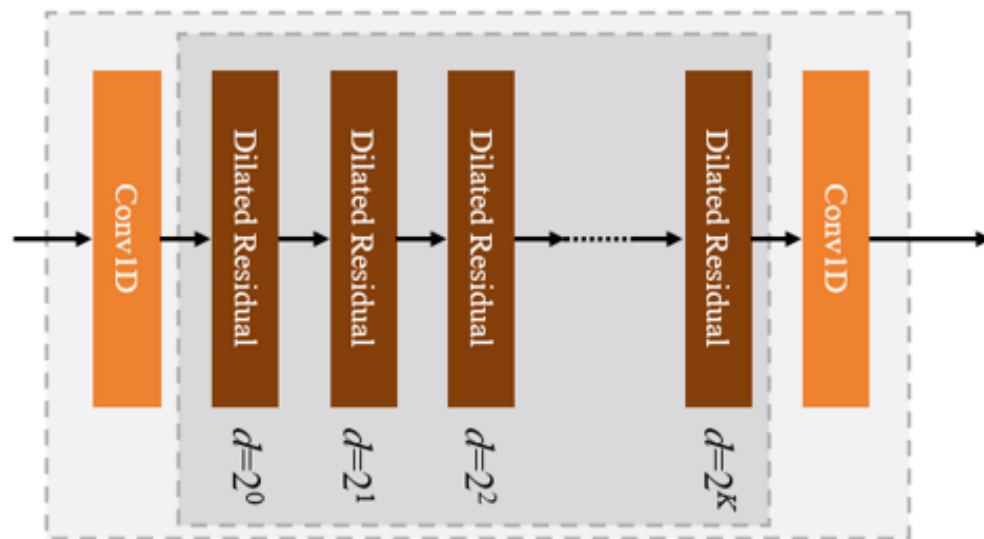
■ 研究内容1：基于注意力机制的心脏病检测模型



(a) the dilated residual block




(b) the dilated convolution layer



(c) the temporal convolutional network



■ 研究内容1：基于注意力机制的心脏病检测模型



Channel-level and spatial-level attention mechanism



■ 研究内容1：基于注意力机制的心脏病检测模型

在2016 PhysioNet/CinC Challenge dataset (PCCD), Kaggle Heartbeat Sounds dataset (KHSD) 和 Yaseen dataset (YSD) 三个公开的数据集上进行了广泛的对比实验，这些数据集涵盖了二类和多类任务

网络结构

Layer↵	Parameters↵	Output size↵	↵
Conv2D↵	3×3, 32, stride 1↵	128×128↵	↵
Max pooling↵	3×3, 32, stride 2↵	64×64↵	↵
Residual unit↵	$\begin{pmatrix} 3\times 3, 64 \\ 3\times 3, 64 \\ 3\times 3, 64 \end{pmatrix} \times 1, \text{ stride } 1$ ↵	64×64↵	↵
Attention TCN block↵	3↵	32×32↵	↵
Residual unit↵	$\begin{pmatrix} 3\times 3, 128 \\ 3\times 3, 128 \\ 3\times 3, 128 \end{pmatrix} \times 1, \text{ stride } 1$ ↵	32×32↵	↵
Attention TCN block↵	2↵	16×16↵	↵
Residual unit↵	$\begin{pmatrix} 3\times 3, 256 \\ 3\times 3, 256 \\ 3\times 3, 256 \end{pmatrix} \times 1, \text{ stride } 1$ ↵	16×16↵	↵
Attention TCN block↵	1↵	8×8↵	↵
Residual unit↵	$\begin{pmatrix} 3\times 3, 512 \\ 3\times 3, 512 \\ 3\times 3, 512 \end{pmatrix} \times 2, \text{ stride } 1$ ↵	8×8↵	↵
Average pooling↵	8×8, 1024, stride 1↵	1×1↵	↵
Dropout↵	0.5↵	1024↵	↵
FC, Softmax↵	#number of classes for heart sound classification↵		↵



■ 研究内容1：基于注意力机制的心脏病检测模型

□ 综合结果表明，RATCNet 在准确度、精确度、召回率和 F1 分数方面普遍优于竞争对手


Comparative performance of different heart sound classification methods on PCCD, KHSD, and YSD.




Dataset \ Model	PCCD				KHSD				YSD			
	acc	prec	rec	F1	acc	prec	rec	F1	acc	prec	rec	F1
KNN	0.8787	0.9323	0.9075	0.9197	0.8469	0.8418	0.8229	0.8801	0.9018	0.9345	0.9285	0.9298
SVM	0.9049	0.9301	0.9470	0.9385	0.8541	0.8483	0.9293	0.8863	0.9732	0.9839	0.9720	0.9776
ELM	0.8611	0.8919	0.9315	0.9113	0.8069	0.8655	0.8506	0.8571	0.9594	0.9690	0.9768	0.9724
ERT	0.8795	0.8852	0.9615	0.9817	0.8741	0.9298	0.8823	0.9033	0.9840	0.9924	0.9920	0.9919
CNN	0.9061	0.9551	0.9208	0.9376	0.8357	0.8817	0.8723	0.8770	0.9508	0.9756	0.9650	0.9699
Resnet50	0.9341	0.9556	0.9584	0.9570	0.8255	0.8546	0.8995	0.8738	0.9731	0.9862	0.9799	0.9729
VGG16	0.9470	0.9576	0.9782	0.9678	0.8240	0.9554	0.7736	0.8542	0.9127	0.9537	0.9445	0.9472
TCN	0.8654	0.9223	0.9000	0.9110	0.8254	0.8606	0.8825	0.8711	0.9746	0.9814	0.9747	0.9778
LSTM	0.9078	0.9618	0.9160	0.9383	0.7983	0.6858	0.7227	0.7029	0.8912	0.9167	0.9266	0.9209
ConvLSTM	0.9670	0.9785	0.9811	0.9798	0.8928	0.9072	0.9362	0.9215	0.9653	0.9832	0.9770	0.9798
Our method	0.9782	0.9875	0.9853	0.9864	0.9286	0.9667	0.9255	0.9457	0.9898	0.9951	0.9949	0.9949




■ 研究内容1：基于注意力机制的心脏病检测模型



PCCD
(a)



KHSD
(b)



YSD
(c)



在不同数据集上的分类性能。(a) PCCD; (b) KHSD; (c) YSD



■ 研究内容1：基于注意力机制的心脏病检测模型

Experimental results of different attention mechanisms.

PhysioNet/Cinc Challenge Dataset						
Model	acc	prec	rec	F1	runtime of each epoch(s)	#total params (10 ⁶)
RATCNet-w/o	0.9670	0.9788	0.9807	0.9797	108.87	44.92
RATCNet-CLA	0.9743	0.9831	0.9854	0.9842	117.33	44.93
RATCNet-SLA	0.9706	0.9817	0.9822	0.9819	113.10	45.03
RATCNet-CLA-SLA	0.9782	0.9875	0.9853	0.9864	120.50	45.04
Kaggle Heartbeat Sounds Dataset						
RATCNet-w/o	0.8912	0.9235	0.9145	0.9184	0.966	44.92
RATCNet-CLA	0.9143	0.9184	0.9574	0.9375	1.134	44.93
RATCNet-SLA	0.9071	0.9551	0.9043	0.9290	1.106	45.03
RATCNet-CLA-SLA	0.9286	0.9667	0.9255	0.9457	1.148	45.04
Yaseen Dataset						
RATCNet-w/o	0.9820	0.9913	0.9885	0.9897	1.48	44.92
RATCNet-CLA	0.9867	0.9916	0.9940	0.9921	1.80	44.93
RATCNet-SLA	0.9832	0.98652	0.9916	0.9888	1.82	45.03
RATCNet-CLA-SLA	0.9898	0.9951	0.9949	0.9949	1.90	45.04



■ 研究内容1：基于注意力机制的心脏病检测模型




Fig. 7. The structure of parallel TCN.




Fig. 8. The structure of sequential TCN.

Results of the parallel and sequential TCN blocks.

PhysioNet/Cinc Challenge Dataset						
Metrics	acc	prec	rec	F1	runtime of each epoch(s)	#total params (10 ⁶)
PTCN	0.9645	0.9756	0.9794	0.9775	60.25	28.48
STCN	0.9670	0.9788	0.9807	0.9797	108.87	44.92
Kaggle Heartbeat Sounds Dataset						
PTCN	0.8841	0.9263	0.8995	0.9122	0.658	28.48
STCN	0.8912	0.9235	0.9145	0.9184	0.966	44.92
Yaseen Dataset						
PTCN	0.9779	0.9894	0.9833	0.9861	1.16	28.48
STCN	0.9820	0.9913	0.9885	0.9897	1.48	44.92



■ 研究内容1：基于注意力机制的心脏病检测模型

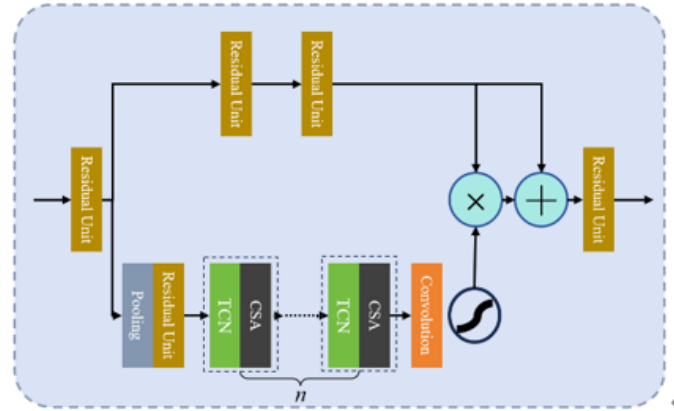


Fig. 9. The use of TCN and CSA in the mask branch.

Results of the impact of the attention mechanism placement on TCN.

PhysioNet/Cinc Challenge Dataset						
Model	acc	prec	rec	F1	runtime of each epoch(s)	#total params (10 ⁶)
CSA+TCN	0.9782	0.9875	0.9853	0.9864	120.50	45.04
TCN+CSA	0.9737	0.9833	0.9844	0.9839	120.65	45.04
Kaggle Heartbeat Sounds Dataset						
CSA+TCN	0.9286	0.9667	0.9255	0.9457	1.148	45.04
TCN+CSA	0.9220	0.9545	0.9231	0.9385	1.316	45.04
Yaseen Dataset						
CSA+TCN	0.9898	0.9951	0.9949	0.9949	1.90	45.04
TCN+CSA	0.9816	0.9911	0.9908	0.9908	1.92	45.04



■ 研究内容1：基于注意力机制的心脏病检测模型

Experimental results versus the number of attention modules.

PhysioNet/Cinc Challenge Dataset						
#Attention blocks	acc	prec	rec	F1	runtime of each epoch(s)	#total params (10 ⁶)
3	0.9670	0.9788	0.9807	0.9797	108.87	44.92
2	0.9618	0.9623	0.9612	0.9618	69.76	11.23
1	0.9479	0.9632	0.9690	0.9661	51.79	2.66
Kaggle Heartbeat Sounds Dataset						
3	0.8912	0.9235	0.9145	0.9184	0.966	44.92
2	0.8849	0.9326	0.8925	0.9121	0.616	11.23
1	0.8827	0.9205	0.8930	0.9101	0.546	2.66
Yaseen Dataset						
3	0.9820	0.9913	0.9885	0.9897	1.48	44.92
2	0.9802	0.9899	0.9844	0.9870	1.24	11.23
1	0.9751	0.9877	0.9782	0.9828	0.88	2.66

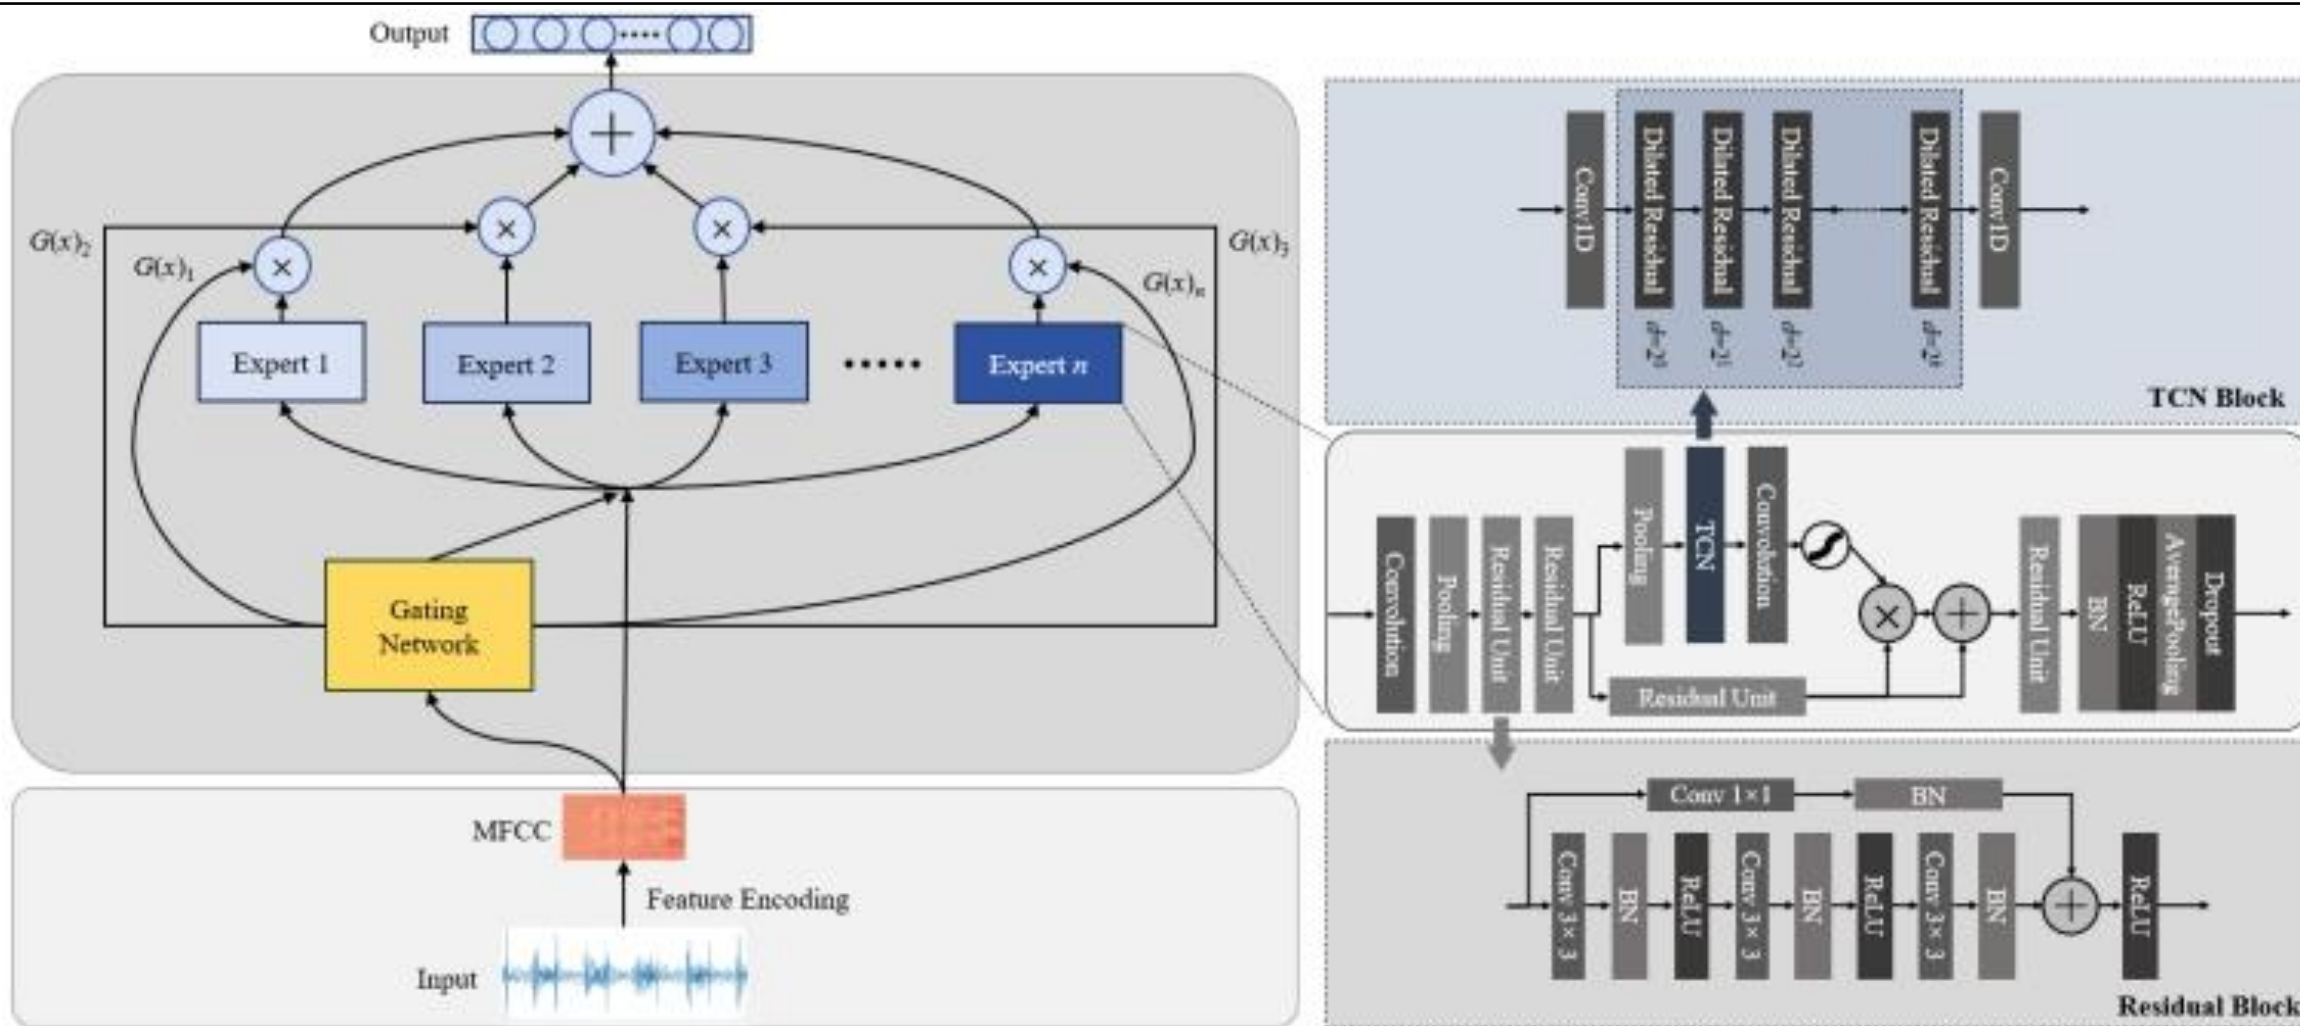


■ 研究内容1：心脏病检测模型

- ❑ Time-series heart sound signals contain complex temporal and spatial dependencies, and thus how to encode the signals largely determines the performance of a heart sound classifier. Traditional heart sound signal analysis methods often use hand-crafted features and classical machine learning models, and their shallow structures prevents them from effectively learning high-order relationships among raw signals. In contrast, deep learning has the end-to-end capacity to jointly learn features and optimizing a classifier
- ❑ Although temporal convolutional networks (TCN) could capture long-term dependencies, support parallel computing, and obtain satisfactory performance, the choice of dilation base and the use of dilation rates largely determine their performance
- ❑ To address this, this study proposes an end-to-end ensembled temporal convolutional networks under the mixture of experts (TCN-MoE) to better capture high-order temporal and spatial dependencies in the raw signals:
 - (1) TCNs ensembled by the mixture of experts are proposed. We first utilize TCNs with different dilation bases for individual heart sound classifier and then jointly optimize the classifiers and a combining strategy. This enables TCN-MoE to have the end-to-end capability
 - (2) Extensive comparative experiments are conducted on public datasets in terms of four performance metrics. Results demonstrate that TCN-MoE outperforms its components and that the use of the mixture of experts performs better than the use of simple majority voting ensemble



■ 研究内容1：心脏病检测模型



样本 c 的损失: $E^c = \sum_{i=1}^n p_i^c \|d^c - o_i^c\|^2$

p_i^c 表示第 i 个专家关于样本 c 的权重

心脏病检测集成模型架构



■ 研究内容1：心脏病检测模型

- Besides the dilation base d , the value of k also has an impact on the performance on TCN
- We here consider the candidate values of 2, 3, and 4

TABLE I. RESULTS OF DIFFERENT HEART SOUND CLASSIFICATION MODELS

	PCCD				KHSD				YSD			
	<i>acc</i>	<i>prec</i>	<i>rec</i>	<i>F1</i>	<i>acc</i>	<i>prec</i>	<i>rec</i>	<i>F1</i>	<i>acc</i>	<i>prec</i>	<i>rec</i>	<i>F1</i>
TCN _{1,2}	93.81%	95.84%	96.09%	0.9596	83.41%	85.81%	91.23%	0.8817	97.60%	98.85%	98.30%	0.9855
TCN _{1,3}	93.91%	96.03%	95.74%	0.9589	86.83%	91.02%	89.31%	0.9008	97.38%	98.72%	97.44%	0.9805
TCN _{1,4}	93.90%	95.81%	96.24%	0.9602	86.70%	90.10%	90.80%	0.9017	97.30%	98.72%	97.40%	0.9801
TCN _{2,2}	94.05%	96.23%	95.99%	0.9611	87.84%	89.45%	93.15%	0.9113	97.90%	98.97%	97.95%	0.9844
TCN _{2,3}	94.01%	95.70%	96.51%	0.9610	86.83%	89.19%	92.10%	0.9046	97.33%	98.70%	97.83%	0.9824
TCN _{2,4}	93.85%	95.68%	96.31%	0.9599	86.55%	91.20%	89.94%	0.9011	97.10%	98.58%	97.05%	0.9778
TCN _{3,2}	93.88%	95.82%	96.21%	0.9601	86.98%	92.05%	88.25%	0.9008	97.75%	98.92%	97.63%	0.9824
TCN _{3,3}	93.23%	94.76%	96.50%	0.9562	85.27%	87.32%	92.30%	0.8938	97.10%	98.60%	97.30%	0.9791
TCN _{3,4}	93.09%	94.63%	96.45%	0.9553	84.70%	87.23%	91.23%	0.8894	96.90%	98.49%	97.20%	0.9781
TCN-MV _{3,2}	94.12%	96.04%	96.29%	0.9617	87.70%	92.09%	89.73%	0.9072	98.30%	99.19%	99.15%	0.9915
TCN-MV _{3,3}	93.94%	95.82%	96.29%	0.9605	87.13%	90.64%	90.38%	0.9038	97.70%	98.89%	98.10%	0.9847
TCN-MV _{3,2}	93.83%	95.58%	96.41%	0.9599	86.83%	89.19%	92.10%	0.9046	97.25%	98.69%	97.06%	0.9782
TCN-MoE _{3,2}	94.76%	96.38%	96.79%	0.9658	89.27%	92.48%	91.46%	0.9195	98.80%	99.42%	99.40%	0.9940
TCN-MoE _{3,3}	94.52%	96.32%	96.73%	0.9652	89.13%	92.65%	91.03%	0.9181	98.60%	99.32%	99.30%	0.9930
TCN-MoE _{3,4}	94.16%	95.79%	96.62%	0.9620	88.98%	91.55%	92.10%	0.9178	98.38%	99.22%	98.56%	0.9887

- TCN _{s,t} in the first column indicates that the TCN's dilation base is s and its dilation rates are s^0, s^1, \dots and s^t



■ 研究内容1：心脏病检测模型




Figure 2. Results of different heart sound classification models on different datasets. (a) PCCD; (b) KHSD; (c) YSD.

- ❑ First, TCNs with different dilation bases obtain mixed classification results across the three datasets
- ❑ Second, we can observe that the value of k has an impact on the recognition performance
- ❑ Third, we can observe that ensemble learning models generally obtains better performance than its individual component
- ❑ Fourth, we can observe that MoE based ensemble learning generally performs better than majority voting-based TCNs



■ 研究内容1：心脏病检测模型

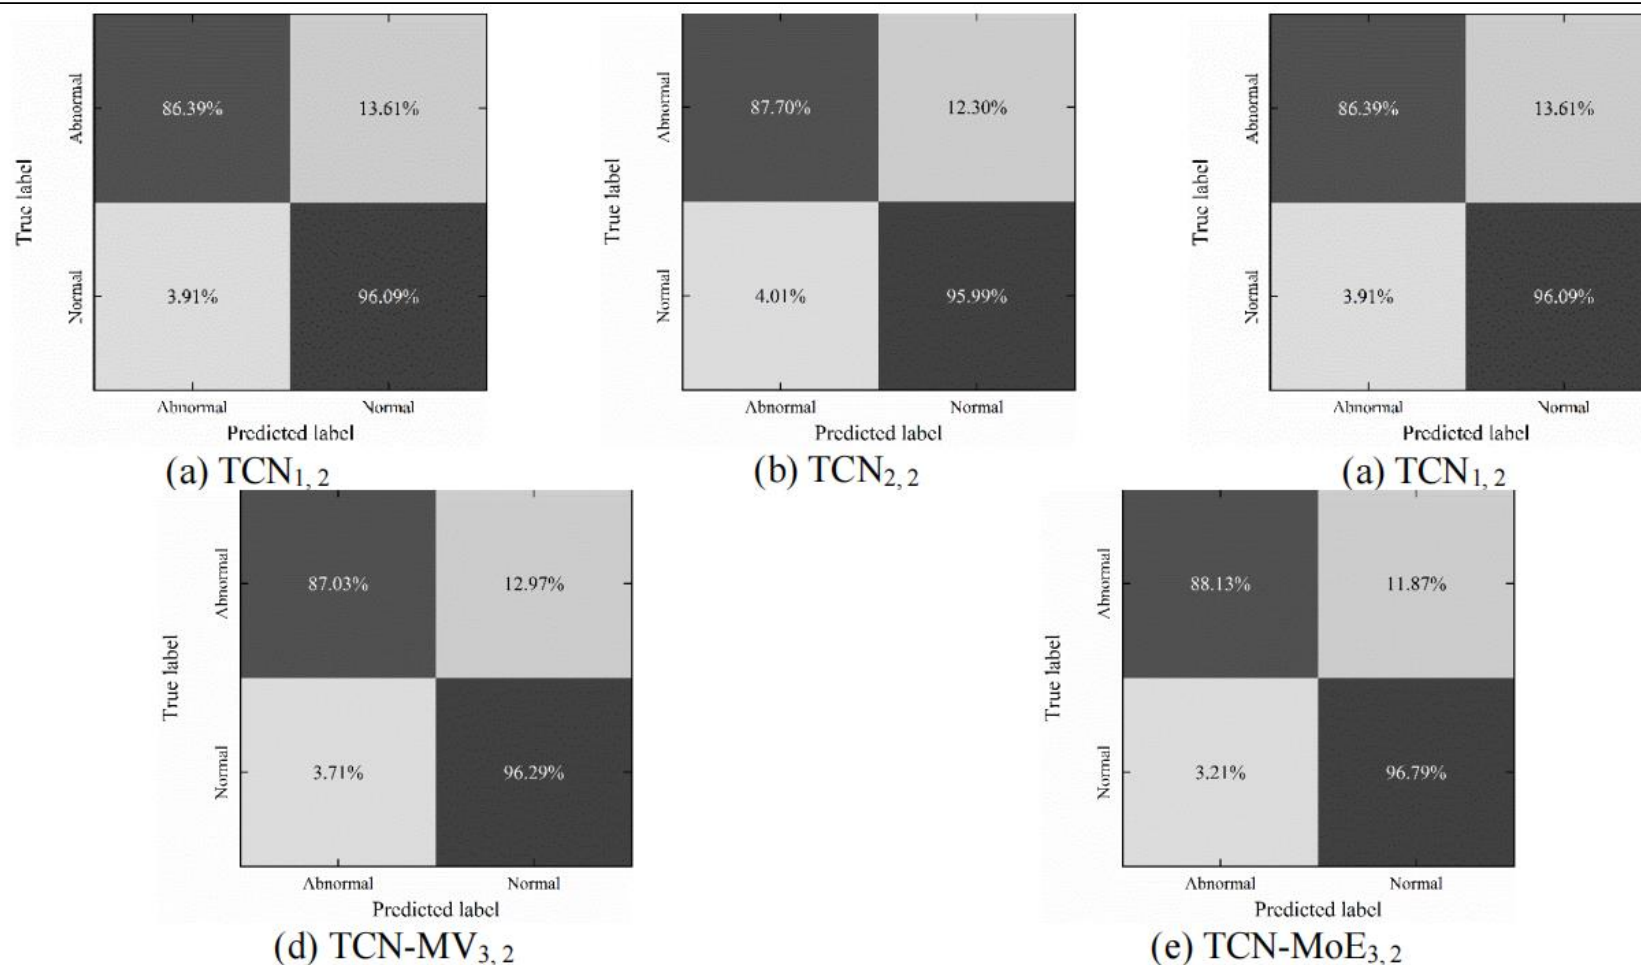
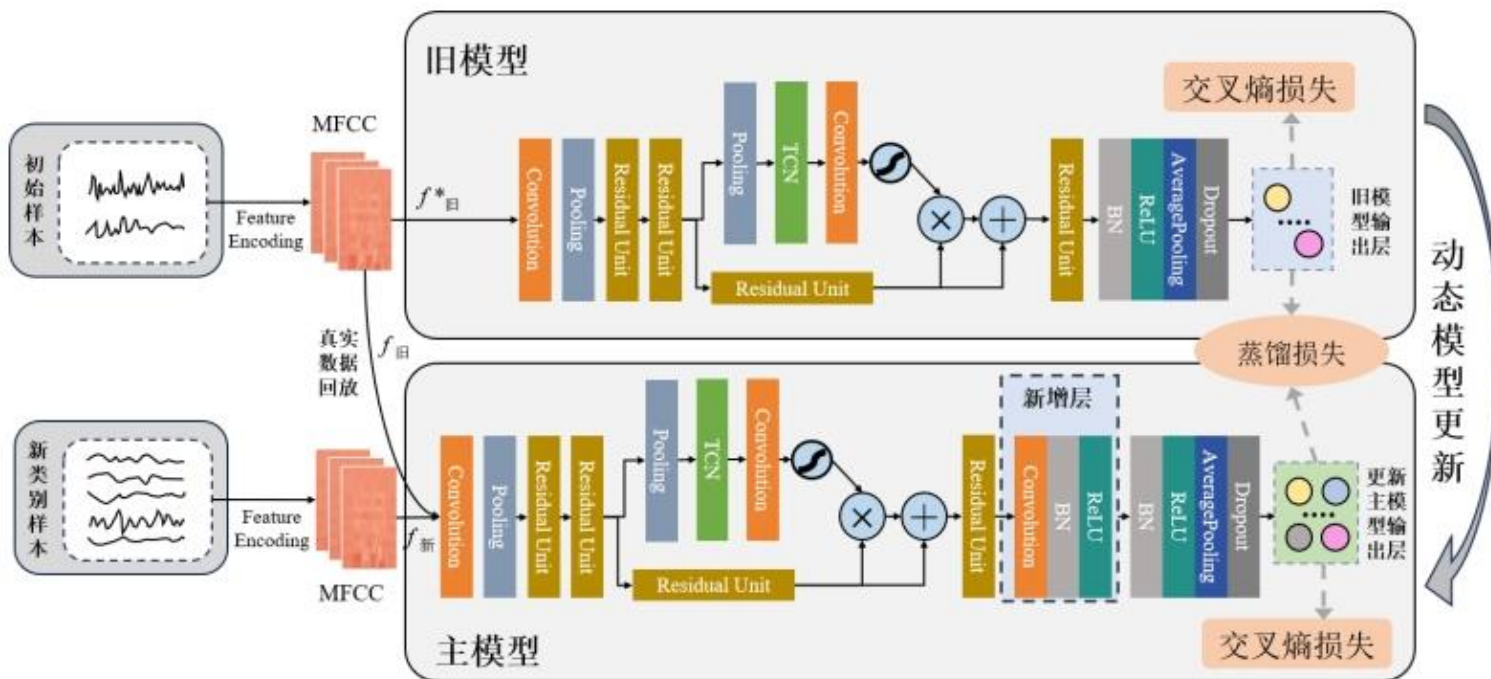


Figure 3. Confusion matrix of different heart sound classification models.

- Furthermore, we present the confusion matrix to evaluate the effectiveness of different heart sound classification models
- We herein only present the results on PCCD. The columns (rows) denote predicted (true) labels
- We can observe that TCN-MoE generally achieves better accuracy

■ 研究内容2：基于增量学习的心脏病检测模型

- ❑ **解决的问题**：调整已有的心脏病预测模型来适用“开放世界”，本研究旨在探索如何有效处理和标准化流式获取的心音数据，如何使得模型能够在开放的世界中动态整合新节点或模块来适应增量学习模型，同时“防止灾难性遗忘”
- ❑ **方法**：本研究提出了一种**结合知识蒸馏、数据回放和网络结构调整**的增量学习方法，以应对在同类心音数据集上逐步学习新类时模型性能退化的问题，并初步完成了基于增量学习的心脏病检测模型，其架构如图3所示。具体来说，在每次增量学习过程中，通过构建并使用旧类示例集（数据回放）维持模型对旧类的记忆，采用蒸馏损失引导新模型输出与旧模型保持一致，同时动态调整网络结构以增强模型的特征表达能力
- ❑ 在数据集上面初步完成**从2类增加到8类**的实验，增量准确率曲线和遗忘率曲线如图4所示。接下来继续对本工作的研究，需要整合较大数据集和更多类别来验证此模型的有效性



基于增量学习的心脏病检测模型

$$L = \alpha \times L_{kl} + (1 - \alpha) \times L_{ce}$$

$$L_{ce}(x) = -\sum_{i=1}^{|C|} y_i \log(p_i)$$

$$L_{kl} = \tau^2 \times \sum_{i=1}^{|C_{old}|} p_i(x) \log \frac{p_i(x)}{q_i(x)}$$



■ 研究内容2：基于增量学习的心脏病检测模型

- ❑ To evaluate the effectiveness of the proposed model, we compile and merge publicly available heart sound datasets along with our private heart sound dataset.
- ❑ The following steps are performed to preprocess heart sound signals. First, the raw signals are processed using a fifth-order Butterworth filter with a frequency range of 25 to 400 Hz to smooth the signals. Next, the filtered signals are downsampled to 2000 Hz and segmented into 5-second audio segments using a sliding window method with a window step size of 2.5 seconds. Then, MFCC and its first-order and second-order differences are extracted from each segment to form feature vectors.

实验数据

Classes	Normal	MS	MR	AS	MVP	AF	EHS	Murmur
Total	1040	255	307	360	271	246	208	356



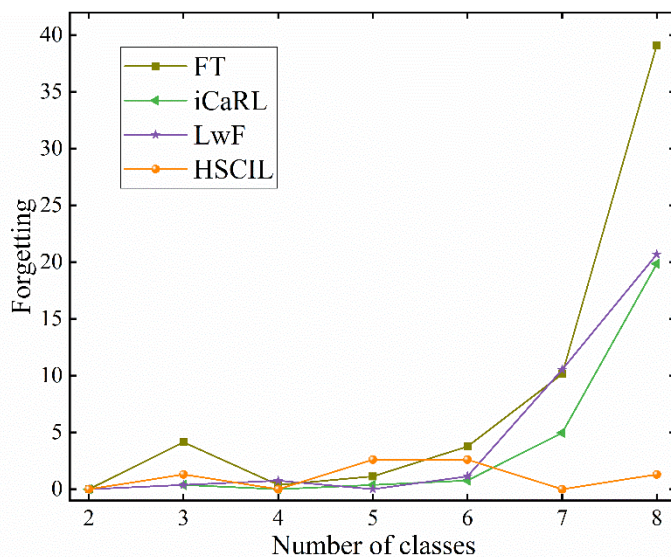
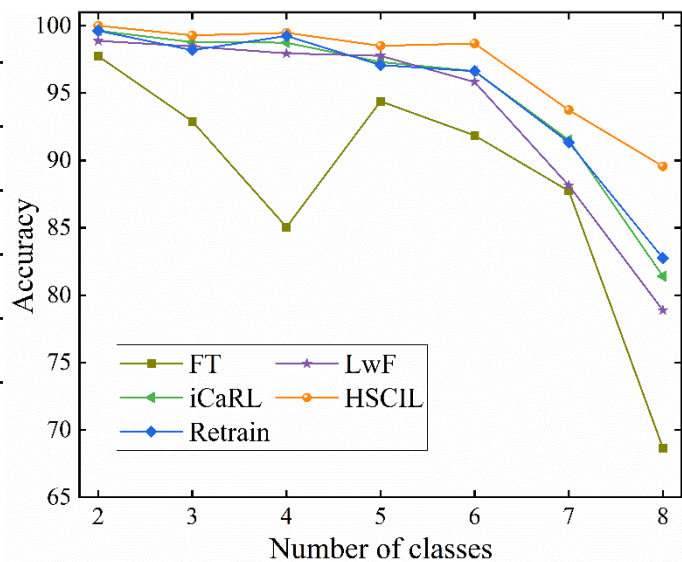
■ 研究内容2：基于增量学习的心脏病检测模型

1) Experiment Results

- In this study, we compare the performance of our method with other four classic methods
- The average incremental accuracy and average incremental forgetting rate, with the best results shown in bold

实验结果

Model	Average accuracy (%)	Average forgetting rate (%)	training time (min)
FT	88.33	8.38	75.27
iCaRL	94.86	3.76	91.08
LwF	93.69	4.78	52.84
HSCIL (ours)	97.03	1.11	102.62
Retraining	94.98	-	196.84



实验结果



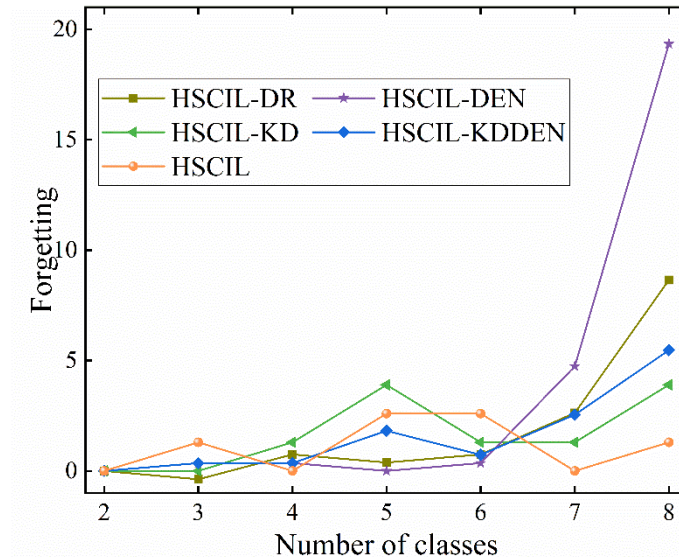

■ 研究内容2：基于增量学习的心脏病检测模型

2) Ablation Results

- we perform ablation experiments to evaluate the effectiveness of each component of HSCIL: using only data replay (HSCIL-DR), using only knowledge distillation (HSCIL-KD), and using only dynamically expanding network (HSCIL-DEN) structure
- The average incremental accuracy and average incremental forgetting rate, with the best results shown in bold

实验结果

Model	Average accuracy (%)	Average forgetting rate (%)
HSCIL-DR	95.30	1.83
HSCIL-KD	95.41	1.67
HSCIL-DEN	95.57	2.85
HSCIL-KDDEN	96.42	1.62
HSCIL	97.03	1.11

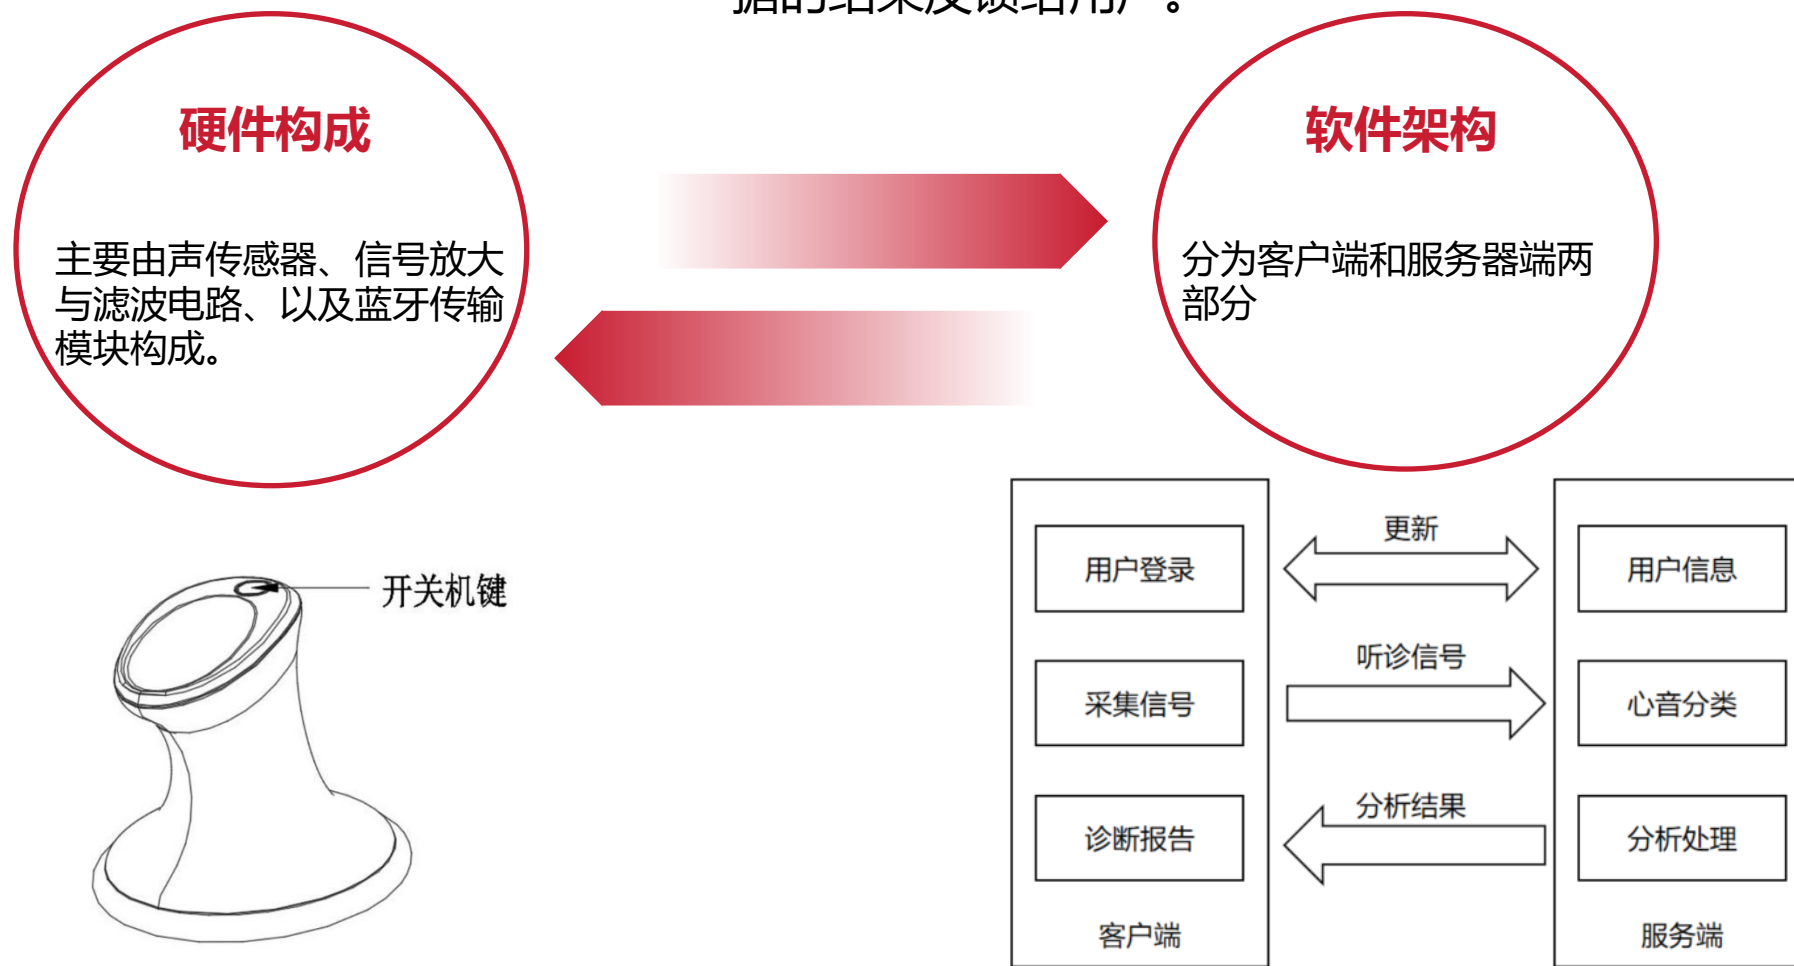


实验结果



■ 研究内容3：心脏病智能检测原型系统

待解决的问题：如何移植模型到平台端并处理采集到的心音数据的结果反馈给用户。



听诊器的硬件构成的概念图

软件的整体架构图



■ 研究内容3：心脏病智能检测原型系统

■ 硬件装置

- 硬件部分以高通QCC3024芯片为控制核心，其具有集成的音频处理功能，包括数字信号处理（DSP）、音频解码和放大。这个芯片的外围通常会有一些滤波和放大电路，以保证采集心音信号的质量；为了滤除电源噪声和低频干扰，设计了由电容和电感组成的滤波电路
- 拾音部分，采用高灵敏度传感器来收集人体心、肺等器官振动发出的声音，音频经滤波及放大处理后，将有效的声音通过蓝牙传输给蓝牙音箱、蓝牙耳机设备，可实时监听人体的心音的听诊



(a) 高通QCC3024芯片




(b) 硬件集成实物图



(c) 听诊器的拾音位置

硬件装置



(d) 实验采集环境



■ 研究内容3：心脏病智能检测原型系统

■ 网站端



在线咨询

咨询心血管疾病相关问题，医生
提供专业回答



专业医疗仪器

专业的蓝牙听诊器设备，记录、
分析心脏问题



健康数据分析

专业的医疗仪器，及时分析您的
健康数据，守护您的健康



共享优质医资

有强大的医资作为保障，守护您
的健康

核心特色

智能蓝牙听诊器设备

启动蓝牙听诊器，并将蓝牙听诊器置于心脏处。将蓝牙听诊器与“健康有声”APP连接，即可进行实时信息收集分析

健康数据分析

分析蓝牙听诊器采集的历史数据，据此提供专业的健康调理建议



待就诊单

患者姓名:

手机号:

病情描述:

紧急程度:

↓ 导出

🔍 搜索

编号	患者姓名	手机号	紧急程度	创建时间	状态	AI结果	症状描述	操作
9910	王公利	1336347910	<div>普通</div>	2024-07-26 12:38:26	待就诊	正常	咳嗽	详情 接诊 删除
9909	李小明	1322241119	<div>普通</div>	2024-07-26 08:42:08	待就诊	正常	鼻塞	详情 接诊 删除
9908	张	1311111111	<div>普通</div>	2024-07-26 08:40:59	待就诊	正常	打喷嚏	详情 接诊 删除
9907	赵	1311111111	<div>普通</div>	2024-07-26 08:39:46	待就诊		流鼻涕	详情 接诊 删除
9906	王	1311111111	<div>普通</div>	2024-07-26 08:38:45	待就诊	正常	鼻塞	详情 接诊 删除
9905	王	1311111111	<div>普通</div>	2024-07-26 08:37:04	待就诊	正常	打喷嚏	详情 接诊 删除
9904	李	1311111111	<div>普通</div>	2024-07-25 14:50:59	待就诊	房颤	心悸	详情 接诊 删除

🏠 概览

🏠 医生概览

🏠 就诊单管理

🏠 就诊单管理

🏠 个人中心

患者姓名:

病情描述: 高1

付款金额: 0

就诊单状态: 待就诊

紧急状态:

普通

创建时间: 2024-07-26 12:38:26

附件: 暂无

心跳录音: <https://dongda.finz.top/api/files/56b4794c-2e0e-4941-bb7f-95b76800c4d7>

AI检测结果: 正常

🗑️ AI检测

0:00 / 0:28

🔊 ⋮

删除选区



1.个人总结

2.背景和相关工作

3.研究内容

4.研究进展

5.下一步工作

- 自监督学习
- 域外泛化
- 迁移学习
- ...